Quantum-Inspired Semantic Modeling for Chinese Word Sense Disambiguation
量子啟發式語意建模應用於中文語意消歧

施子嚴 Zi-Yan Shi

Department of Engineering Science and Ocean Engineering

National Taiwan University

collaborate with Chih-Han Lin, Liang-Hsuan Chou, Wei-Cheng Lin

語意消歧 (Word Sense Disambiguation, WSD) 是自然語言處理 (Natural Language Processing, NLP) 之中的一個重要的課題，對於中文這樣一字多義的狀況普遍存在的語言之中尤其如此。傳統的語言模型將單字表示為單一一個確定的靜態向量，難以捕捉歧義所帶來的模糊與疊加特性。因此，本專案引入「量子啟發式語意建模」框架，利用量子電腦可以處理密度矩陣 (Density Matrices) 的混合，來對多義詞進行建模與消歧義。我們比較了傳統的餘弦相似度模型 (Cosine Similarity)、量子純態模型 (Quantum Pure State model)，以及所提出的量子混合態模型 (Quantum Mixed State Model)。在中文語意網路 (Chinese-Wordnet-SemCor, CWN) 資料集上的實驗顯示，雖然純態模型相較於傳統 Cosine 模型炳梧優勢，但將句子視為語意子空間機率集合的量子混合態模型，在較長文本情境下取得了顯著的準確度提升 (相對增益達 25%)。我們的結果展示了量子電腦應用於語言不確定性建模的潛力。

I. INTRODUCTION

A. 研究背景

在計算語言學領域，語意消歧 (Word Sense Disambiguation, WSD) 仍然是人工智慧模型理解語言的關鍵瓶頸之一。當同一個字詞根據上下文而具有多種不同意義時，語言模型便難以分辨並確定該字詞的具體意義為何者。例如，中文詞「打」可以表示「打球」(例如籃球)、「打毛衣」(編織)，或「打人」(毆打)。

從語言學角度來看，歧義並不是隨機出現，而是有結構的。如 Pustejovsky [1] 指出，一詞多義可以是規律性的、生成性的，往往需要「生成詞彙」方法 (Generative Lexicon) 來動態解析每個案例中的語意。Apresjan [2] 則將「規律性的一詞多義」定義為詞類間共享的系統性語意變換。Hsieh et al. [3] 的研究又指出，即使是專有名詞也展現出這種規律性一詞多義的現象。因此，我們需要一個超越傳統窮舉比對的語意消歧策略。

B. 古典語意模型的瓶頸

現代自然語言處理主要依賴向量空間模型 (Vector Space Model，VSM)，例如流行的 BERT 或 BGE 模型。這些模型將詞彙映射為高維歐幾里得空間中的單一向量。雖然對於一般任務有效，但這種表示法面臨理論限制：

1. **歧義的塌縮：**單一向量強迫將所有潛在意義「塌縮」成一個平均表示。

2. **分布資訊的流失：**它缺乏數學結構來建模在上下文完全解析之前意義的「疊加」狀態。

C. 研究動機

為了解決這些限制，我們引進量子力學 (Quantum Mechanics, QM) 的機率框架的幫助。van Rijsbergen [4] 提出了「資訊檢索幾何」，並認為量子邏輯能更好地建模資訊中的不確定性。

在語意消歧領域，Tamburini [5] 證明了「類量子」方法，將詞彙表示為複數向量 (純態) 來進行傳統語意消歧任務，此外 Zhang et al. [6] 則提出將詞彙表示建模為密度矩陣來進行計算，並主張混合態具有捕捉語意中不確定與蘊含關係的潛力。

奠基於上述的研究，本研究實作並評估了量子混合態模型。透過將句子表示為密度矩陣，並利用 Qiskit [7] 在量子位元上進行操作，希望展示量子混合態模型能夠捕捉語意的「模糊性」，以及其在處理複雜上下文時的穩健性。

II. PROBLEM AND METHODOLOGY

在本節中，我們正式定義語意消歧（WSD）問題，並詳細說明三種不同的建模方法：古典餘弦相似度基準、量子純態模型，以及量子混合態模型。

A. 古典基準：餘弦相似度 (Cosine Similarity)

本研究選用 **BAAI/bge-large-zh-v1.5** 模型作為語意編碼器 [8]。令 S 為包含目標詞 w 的輸入句子，D 為候選定義。

- **向量表示：**模型將句子上下文和定義都映射到高維實向量空間 $\mathbb{R}^d$ ($d = 1024$)。

$$\vec{v}_S = \text{Encoder}(S, w), \quad \vec{v}_D = \text{Encoder}(D, w) \tag{1}$$

- **相似度度量：**餘弦相似度利用兩向量之間的夾角來量化相似度。

$$\text{Sim}(S, D) = \frac{\vec{v}_S \cdot \vec{v}_D}{\|\vec{v}_S\| \|\vec{v}_D\|} \tag{2}$$

B. 量子計算框架

為了將傳統演算法移植到量子機器, 我們將古典向量映射到量子希爾伯特空間 (Hilbert Space) $\mathcal{H}$.

1. 空間映射

維度為 d 的古典嵌入向量可以映射到一個擁有 n 個量子位元的量子系統，前提是希爾伯特空間維度 $2^n \geq d$ 44。對於 $d = 1024$ 的 BGE-large，我們需要 $n = log_2(1024) = 10$ 個量子位元 (Qubits) [7]。

2. 振幅編碼

我們採用振幅編碼將古典向量 $\vec{v}$ 轉換為量子態向量 $|\psi\rangle$。古典向量使用 L_2 歸一化，以確保滿足量子機率約束 $\langle\psi|\psi\rangle = 1$:

$$|\psi\rangle = \sum_{i=0}^{2^n-1} c_i |i\rangle, \quad \text{where } c_i = \frac{v_i}{\|\vec{v}\|_2} \tag{3}$$

C. 量子純態模型 (Pure State)

在此方法中，句子和定義都被視為單一、相干的量子態，類似於 Tamburini [5] 的定義，但為了與原始的嵌入向量相容，我們使用實值振幅來實作。

- **狀態準備：**
  - 句態: $|\psi_S\rangle = \text{Encode}(\vec{v}_S)$
  - 定義態: $|\phi_D\rangle = \text{Encode}(\vec{v}_D)$
- **測量：**我們使用玻恩定則 (Born Rule) 計算投影機率：

$$P(\text{Match}) = |\langle\phi_D|\psi_S\rangle|^2 = \text{Tr}(\rho_S \cdot \Pi_D) \quad (4)$$

where $\rho_S = |\psi_S\rangle\langle\psi_S|$ and $\Pi_D = |\phi_D\rangle\langle\phi_D|$.

D. 量子混合態模型 (Mixed State)

啟發自先前語意匹配對偶性 [9] 的研究，我們提出的模型假設，一個含多義詞的句子更適合表示為語意態的統計集合（混合態），而非單一相干態。

1. 語意分塊

我們將原本的句子分割成 m 個包含目標詞的重疊句塊。令 $|\psi_j\rangle$ 為第 j 個切塊的純態編碼。

2. 構建密度矩陣

我們構建一個密度矩陣 ρ_{mixed} 來表示原句子：

$$\rho_{mixed} = \sum_{j=1}^{m} w_j |\psi_j\rangle\langle\psi_j| \quad (5)$$

其中 w_j 是句塊 j 的古典機率權重 ($\sum w_j = 1$)。不同於單純的向量和，這個矩陣沿著對角線保留了每個語意成分的獨特性，維持歧義式機率分布的狀態。

3. 相似度測量

將定義態作為測量基底，相似度計算即為定義算子對句子密度矩陣測量的期望值：

$$P(\text{Match}) = \langle\phi_D|\rho_{mixed}|\phi_D\rangle = \sum_{j=1}^{m} w_j |\langle\phi_D|\psi_j\rangle|^2 \quad (6)$$

藉由這個步驟，我們在句子的所有語意子空間中進行加權搜尋，過濾出與定義最佳對齊的那個，當作預測結果。

III. RESULTS AND ANALYSIS

A. 實驗設置

- **資料集：** `lopentu/Chinese-Wordnet-SemCor` [3] (抽取自中文語意網路 [10])。
- **資料分割：**為了測試我們的方法對不同資訊密度的句子的穩健性，我們根據句子長度分割測試集，並且每次測試從其中各抽樣一百則量測準確度，進行三重複測試：
  - **短文本集：**句子 ≤ 15 字元。
  - **長文本集：**句子 ≥ 30 字元。
- **衡量指標：**
  - **Top-K 準確度：**模型預測的第 K 名是否為正確答案。

- **平均倒數排名 (Mean Reciprocal Rank, MRR)：**對於每個測試案例，找出正確答案的排名位置，取其倒數，然後平均。正確答案的位置排越前面分數越高。
- **邊界值 (Margin)：**第一名預測分數與第二名預測分數之間的差距。Margin 越大，表示模型對自己的預測越有信心。

B. Quantitative Results

下表總結了三種方法的表現。

C. 分析

1. 純態等價於傳統演算法：量子純態模型在兩項任務中的準確度表現與餘弦基準線完全相同。這證實了我們將語言模型產生的古典嵌入向量，映射到希爾伯特空間之後，仍能保留嵌入的幾何資訊。Margin 的些微差異則是由於量子計算的不確定性導致的。

2. 長文本的優勢：雖然古典模型隨著上下文長度增加而表現顯著退化 (從 0.32 降至 0.25)，但是量子混合態模型仍保持了 0.3133 的高水準的準確度，相較於 baseline 提升超過 25%。

3. Top-K and MRR Gains: 在困難的長文本任務中，混合態模型不僅改善了 Top-1 準確度，還提升了 Top-2、Top-3 準確度和 MRR。這表示模型更有機會將正確語意帶入預測的前幾名。

IV. DISCUSSION AND CONCLUSION

A. Discussion

排名 vs. 猜測：我們觀察到平均倒數排名（MRR）的顯著改善，因此可以推斷量子混合態模型的成功不僅僅是幸運猜測，而是可以系統性地將正確定義排名得比基準線更高。這表示我們提出的量子混合態模型方法可以有效地「推動」正確的語意子空間更接近定義向量。

密度矩陣作為語意集合：我們的結果驗證了密度矩陣的混合態能夠更好的描述語言歧義。單一向量（純態）會把特徵平均化，在長句子中往往把語意的訊號稀釋掉。相比之下，混合態 ρ 維持了機率分布，當投影到定義 $|\phi_D\rangle$ 時，它扮演「語意過濾器」的角色，我們可從集合中提取出最大的機率投影。

B. 未來方向

基於我們的實驗結果，我們提出兩個可能的研究方向：

- **分塊策略：**目前的分塊策略是固定長度的。未來研究可以探索動態的分塊方式，使語言模型更專注於關鍵的片段。
- **錯誤分析：**除了本研究提供的指標之外，未來研究可以詳細的分析錯誤來源，以理解量子模型在特定語言模式 (例如成語或隱喻) 中表現優良或失敗的地方。

TABLE I. 短文本集（長度 ≤ 15）的平均結果。混合態模型顯示些微優勢。

Method	Acc	Top-2	Top-3	MRR	Margin
Cosine Baseline	0.3200	0.5033	0.6333	0.5160	0.0377
Quantum (Pure)	0.3200	0.5033	0.6333	0.5160	**0.0400**
Mixed State	**0.3400**	**0.5033**	**0.6333**	**0.5244**	0.0388

TABLE II. 長文本集（長度 ≥ 30）的平均結果。可見混合態模型展現顯著的優勢。

Method	Acc	Top-2	Top-3	MRR	Margin
Cosine Baseline	0.2500	0.4600	0.6200	0.4770	0.0311
Quantum (Pure)	0.2500	0.4600	0.6200	0.4770	0.0295
Mixed State	**0.3133**	**0.4900**	**0.6267**	**0.5210**	**0.0331**

C. 結論

本研究成功實作了一個應用於中文語意消歧的量子啟發式語意建模框架，證明了我們提出的量子混合態模型在處理長文本的語言歧義時具有顯著的優勢。這個結果驗證了引入量子力學為自然語言處理提供了一個更具表達力和穩健性的方案。

ACKNOWLEDGMENTS

個人感謝國立臺灣大學量子計算課程所提供的教學。

[1] J. Pustejovsky, *The Generative Lexicon* (MIT Press, 1998).

[2] J. D. Apresjan, Regular polysemy, Linguistics **12**, 5 (1974).

[3] S.-K. Hsieh, Y.-H. Tseng, H.-Y. Chou, C.-W. Yang, and Y.-Y. Chang, Resolving regular polysemy in named entities, arXiv preprint arXiv:2401.09758 (2024).

[4] C. J. van Rijsbergen, *The Geometry of Information Retrieval* (Cambridge University Press, 2004).

[5] F. Tamburini, A quantum-like approach to word sense disambiguation, in *Proceedings of the International Conference on Recent Advances in Natural Language Processing (RANLP 2019)* (INCOMA Ltd., Varna, Bulgaria, 2019) pp. 1176–1185.

[6] C. Zhang, Q. Li, Z. Su, and D. Song, Word2state: Modeling word representations as states with density matrices, Chinese Journal of Electronics **34**, 649 (2025).

[7] e. a. Javadi-Abhari, Ali, Quantum computing with qiskit, arXiv preprint arXiv:2405.08810 (2024).

[8] S. Xiao, Z. Liu, P. Zhang, N. Muennighoff, D. Lian, and J.-Y. Nie, C-pack: Packed resources for general chinese embeddings, in *Proceedings of the 47th International ACM SIGIR*

Conference on Research and Development in Information Retrieval, SIGIR '24 (2024) p. 641–649.

[9] C. Zhang, Q. Li, D. Song, and P. Tiwari, Quantum-inspired semantic matching based on neural networks with the duality of density matrices, Engineering Applications of Artificial Intelligence **140**, 109667 (2025).

[10] C.-R. Huang, S.-K. Hsieh, and J.-F. Hong, Chinese wordnet: Design, implementation, and application of an infrastructure for cross-lingual knowledge processing, Journal of Chinese Information Processing **24**, 14 (2010).

Appendix A: Qiskit Code

You may access our code at https://drive.google.com/file/d/11ra2oqDF54bTjmiviowuleD8t5-7u-rC/view?usp=sharing